

# 正交性

颜文斌

清华大学

# 内容提要

- 正交性
- 投影
- 最小二乘法
- 正交基和Gram-Schmidt法则

# 向量的内积

- (欧式空间中) 向量的内积 (点乘) (平面直角坐标系) :

$$v \cdot w = \sum_{i=1}^n v_i w_i$$

- 把列向量看成矩阵

$$v \cdot w = \sum_{i=1}^n v_i w_i = v^T w$$

# 正交性 (orthogonality)

- 两个向量正交 $\Leftrightarrow$ 点乘为0

$$v \cdot w = v^T w = 0$$

- 向量和正交，则

$$\|v\|^2 + \|w\|^2 = \|v + w\|^2$$

- 证明：

- 右边 $= (v + w)^T(v + w) = v^T v + w^T w =$ 左边

- 例：

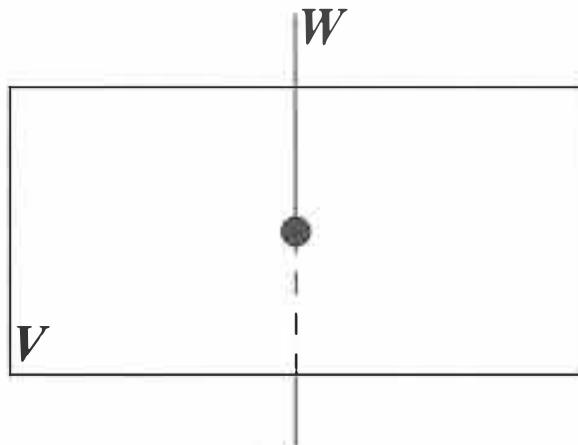
- 零向量和所有向量正交

# 线性子空间之间的正交性

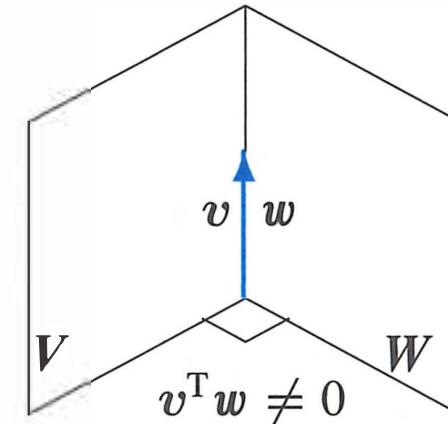
- 一个线性空间的两个子空间 $V$ 和 $W$ 是正交的，如果 $V$ 中的每一个向量和 $W$ 中的每一个向量都是正交的

$$v^T w = 0 \text{ for all } v \text{ in } V \text{ and all } w \text{ in } W$$

- 例：



orthogonal plane  $V$  and line  $W$

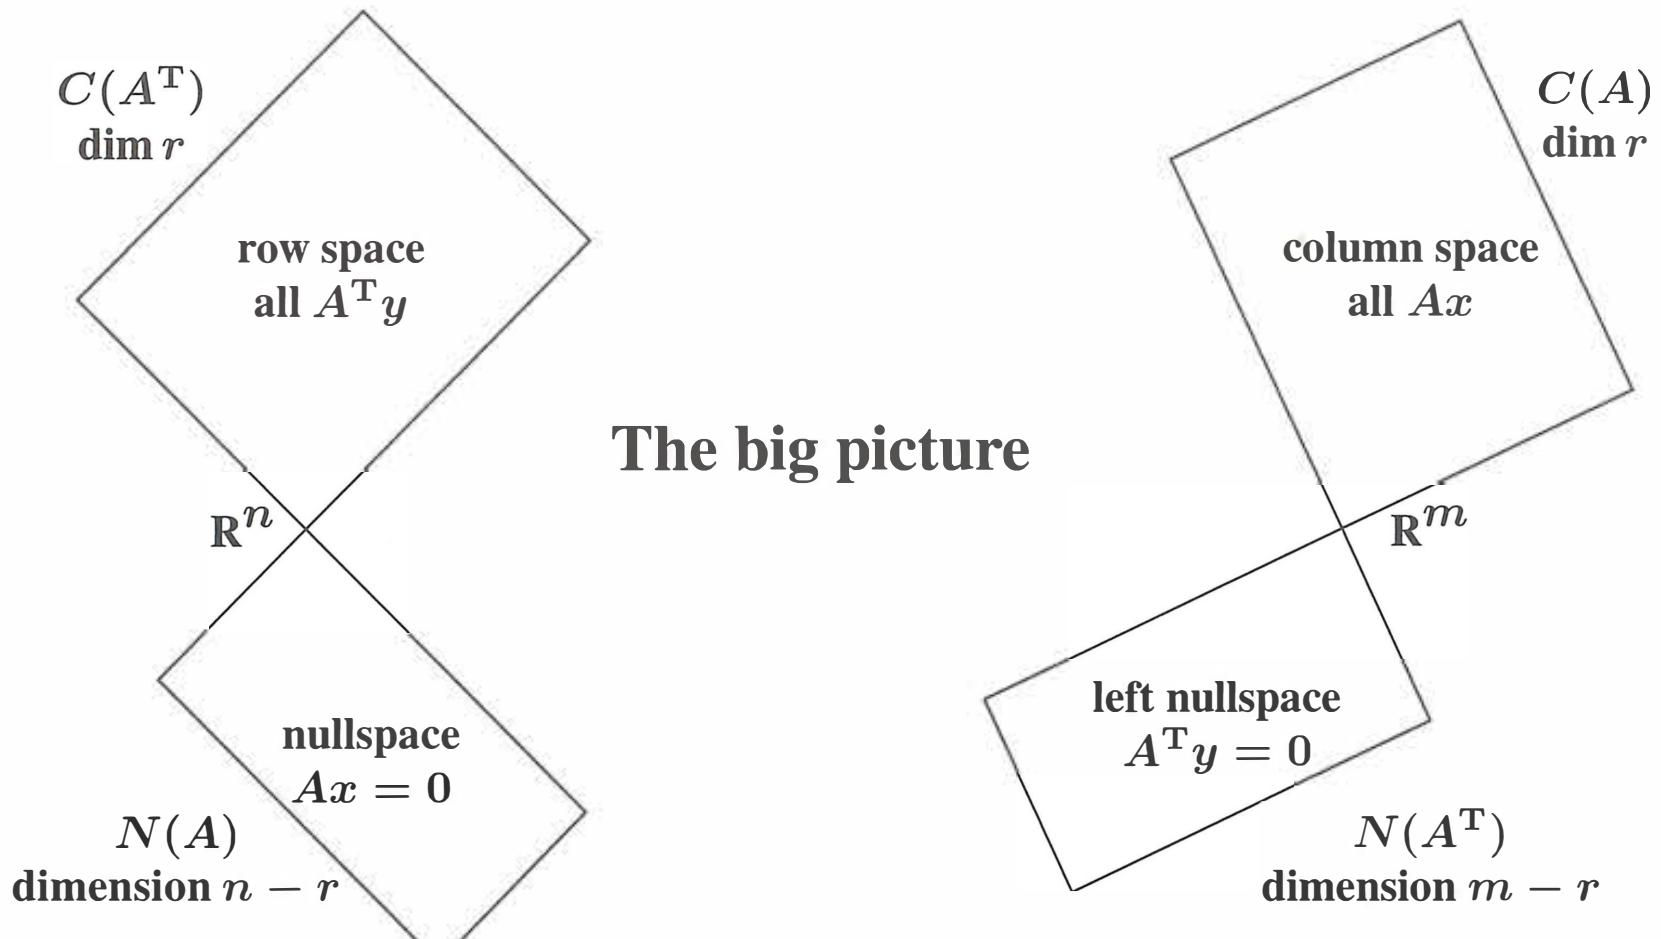


non-orthogonal planes

# 线性子空间的正交性

- 命题： $L$ 中的子空间 $V$ 和 $W$ 正交，则 $\dim V + \dim W \leq \dim L$
- 证明思路：
  - 如果 $V$ 和 $W$ 正交，则 $V$ 基和 $W$ 的基之间的内积是0
  - 则 $V$ 基不能写成 $W$ 的基的线性组合，反之亦然
  - $V$ 基和 $W$ 的基的并集是线性无关的，由维度定义，他们的数量少于等于 $\dim L$

# 矩阵的四个子空间之间的正交性



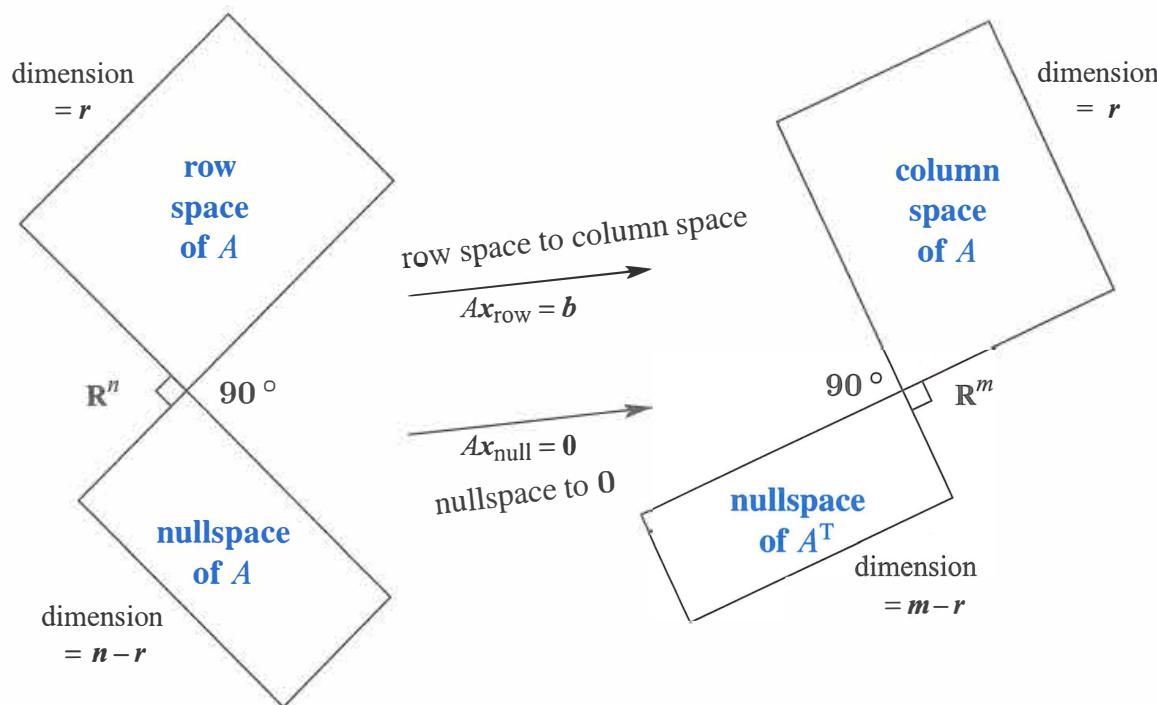
# 矩阵的四个子空间之间的正交性

- 矩阵 $A$ 的零空间 $N(A)$ 和行空间 $C(A^T)$ 是 $\mathbb{R}^n$ 中的正交子空间
- 证明一：
  - $N(A)$ 中的元素 $x$ 满足 $Ax = 0$ , 也就是说 $x$ 同 $A$ 的每一行正交, 所以 $N(A)$ 和 $C(A^T)$ 正交
- 证明二：
  - $C(A^T)$ 中任一的元素 :  $A^T y$ 。  $N(A)$ 中的元素 $x$ 满足 $Ax = 0$
  - $x^T A^T y = (Ax)^T y = \mathbf{0}^T y = 0$

$$Ax = \begin{bmatrix} 1 & 3 & 4 \\ 5 & 2 & 7 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \quad \text{gives the dot products} \quad \begin{aligned} 1 + 3 - 4 &= 0 \\ 5 + 2 - 7 &= 0 \end{aligned}$$

# 矩阵的四个子空间之间的正交性

- 矩阵 $A$ 的零空间 $N(A)$ 和行空间 $C(A^T)$ 是 $\mathbb{R}^n$ 中的正交子空间
- 矩阵 $A$ 的左零空间 $N(A^T)$ 和列空间 $C(A)$ 是 $\mathbb{R}^m$ 中的正交子空间



# 正交补 (orthogonal complement)

- 正交补：子空间 $V$ 的正交补 $V^\perp$  由所有同 $V$ 正交的向量组成
- 例：
  - $N(A)$ 是 $C(A^T)$ 的正交补
  - $N(A^T)$ 是 $C(A)$ 的正交补
- 只有零向量同时属于 $V$ 和 $V^\perp$

# 线性代数基本定理（第二部分）

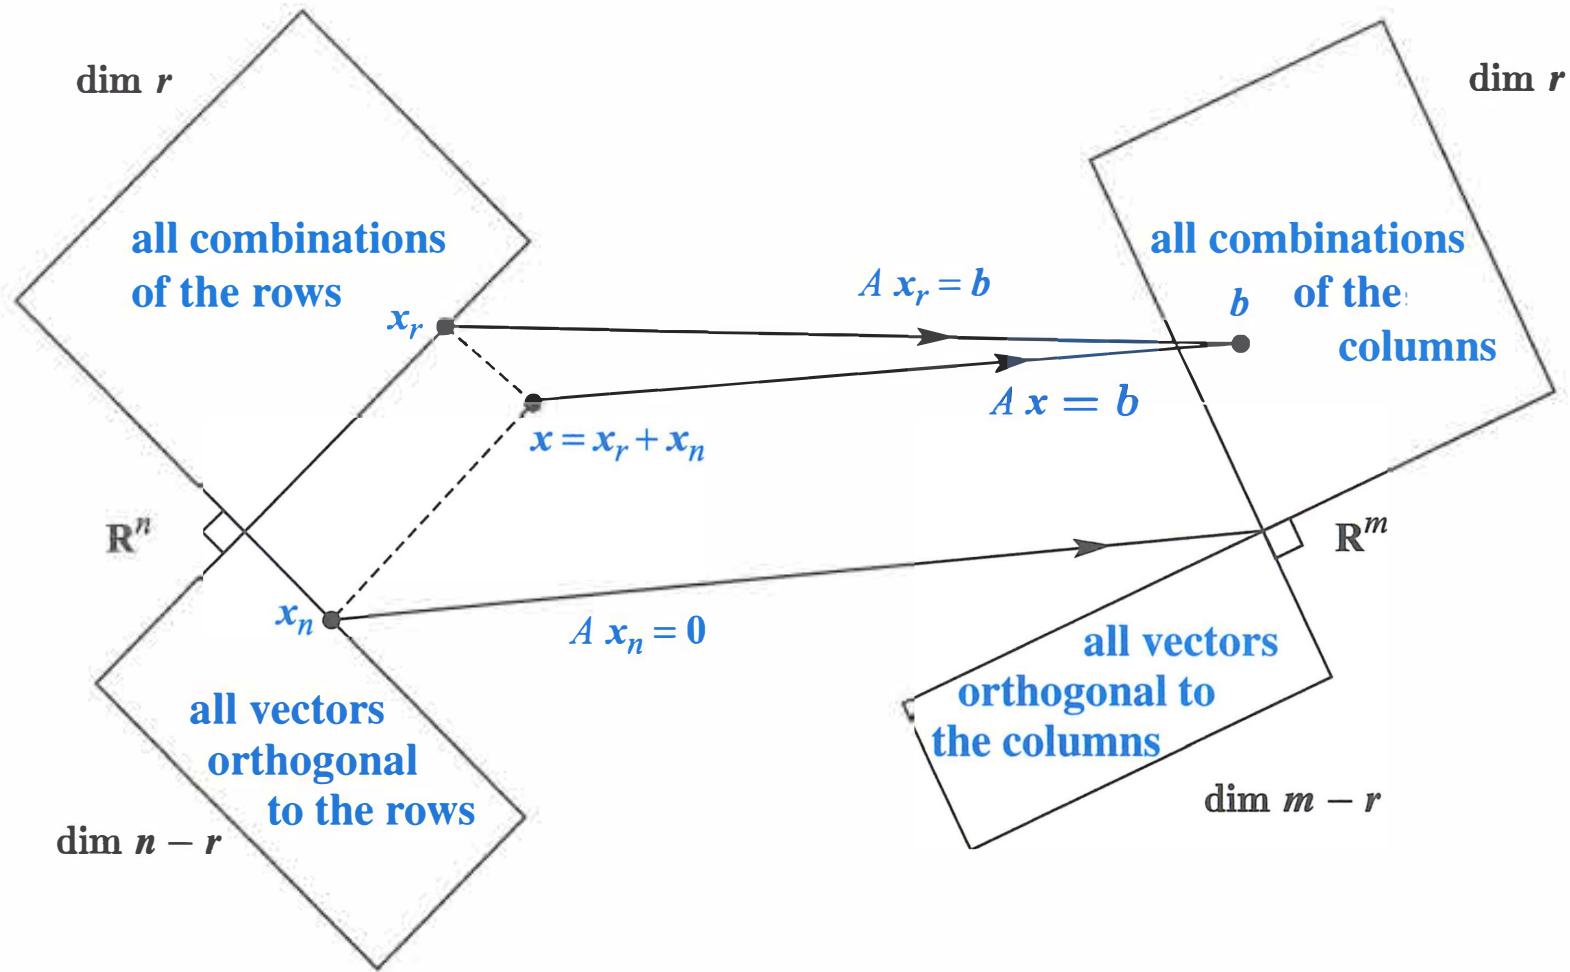
- 线性代数基本定理（第二部分）：
  - $N(A)$  是  $C(A^T)$  的正交补（在  $\mathbb{R}^n$  中）
  - $N(A^T)$  是  $C(A)$  的正交补（在  $\mathbb{R}^m$  中）
- 任何一个  $\mathbb{R}^n$  中的向量可以分解  $x = x_r + x_n$ , 且  $x_r \in C(A^T)$ ,  $x_n \in N(A)$ 
  - $Ax = A(x_r + x_n) = Ax_r \in C(A^T)$
- 对于任意的  $b \in C(A^T)$ , 存在唯一的  $x_r \in C(A^T)$ , 使得  $Ax_r = b$ 
  - 证明思路：假设不唯一，则  $Ax_r = Ax'_r$ , 则  $x_r - x'_r$  既属于  $N(A)$ , 又属于  $C(A^T)$ 。 $x_r - x'_r$  只能为  $\mathbf{0}$

# $\mathbb{R}^n$ 分解为 $N(A)$ 和 $C(A^T)$

- 任何一个 $\mathbb{R}^n$ 中的向量可以分解 $x = x_r + x_n$ , 且 $x_r \in C(A^T)$ ,  $x_n \in N(A)$ 
  - $Ax = A(x_r + x_n) = Ax_r \in C(A^T)$
- 对于任意的 $b \in C(A^T)$ , 存在唯一的 $x_r \in C(A^T)$ , 使得 $Ax_r = b$
- **矩阵的可逆部分**: 对于矩阵 $A$ , 把 $N(A)$ 和 $N(A^T)$ 对应的列和行去掉之后总是一个 $r \times r$ 的可逆矩阵
- 例 :

$$A = \begin{bmatrix} 3 & 0 & 0 & 0 & 0 \\ 0 & 5 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad \begin{bmatrix} 3 & 0 \\ 0 & 5 \end{bmatrix} \quad B = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 \\ 1 & 2 & 4 & 5 & 6 \\ 1 & 2 & 4 & 5 & 6 \end{bmatrix} \quad \begin{bmatrix} 1 & 3 \\ 1 & 4 \end{bmatrix}$$

# Big Picture (升级版)



# 小结

## ■ REVIEW OF THE KEY IDEAS ■

1. Subspaces  $V$  and  $W$  are orthogonal if every  $v$  in  $V$  is orthogonal to every  $w$  in  $W$ .
2.  $V$  and  $W$  are “orthogonal complements” if  $W$  contains **all** vectors perpendicular to  $V$  (and vice versa). Inside  $\mathbf{R}^n$ , the dimensions of complements  $V$  and  $W$  add to  $n$ .
3. The nullspace  $N(A)$  and the row space  $C(A^T)$  are orthogonal complements, with dimensions  $(n - r) + r = n$ . Similarly  $N(A^T)$  and  $C(A)$  are orthogonal complements with  $(m - r) + r = m$ .
4. Any  $n$  independent vectors in  $\mathbf{R}^n$  span  $\mathbf{R}^n$ . Any  $n$  spanning vectors are independent.

# 内容提要

- 正交性
- 投影
- 最小二乘法
- 正交基和Gram-Schmidt法则

# 投影 (projection) 举例

- 问题1：向量  $\mathbf{b} = (2, 3, 4)^T$  在z轴和xy平面上的投影分别是多少？
  - 向量在某条直线的投影？从端点做一条垂直于该直线的垂线
  - 向量在某平面的投影？从端点做一条垂直于该平面的垂线
  - 换句话说：目标直线/平面上最接近原向量的点
- 答案：分别是  $\mathbf{b}_z = (0, 0, 4)^T$  和  $\mathbf{b}_{xy} = (2, 3, 0)^T$
- 问题2：能否找到矩阵  $P_z$  和  $P_{xz}$  使得  $\mathbf{b}_z = P_z \mathbf{b}$ ,  $\mathbf{b}_{xy} = P_{xz} \mathbf{b}$  ? 这些矩阵有什么性质？

$$P_1 = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad P_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

# 投影举例

- z轴和xy平面是 $\mathbb{R}^3$ 中的正交子空间

$$P_z \mathbf{b} \cdot P_{xy} \mathbf{b} = 0$$

- z轴和xy平面在 $\mathbb{R}^3$ 中互为正交补

$$P_z \mathbf{b} + P_{xy} \mathbf{b} = \mathbf{b}, \quad P_z + P_{xy} = I$$

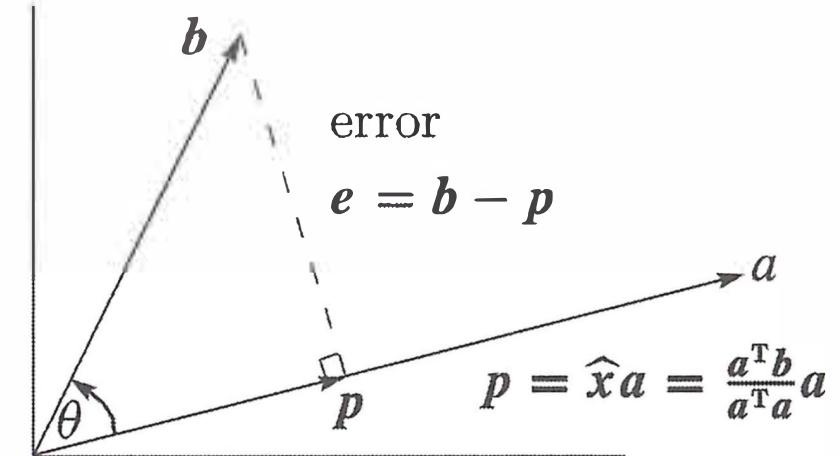
- $P_z^2 = P_z$

- 对于一般的子空间怎么找投影？

- 首先：如何描述某个子空间？用它的基。看成基构成的矩阵的列空间

# 投影到过原点的直线上

- 考虑一条过原点的直线 $L$ , 它的方向沿着向量 $\mathbf{a}$ 
  - $\{\text{直线每一点}\} = C(\mathbf{a})$
- 向量 $\mathbf{b}$ 在直线 $L$ 上的投影 $\mathbf{p}$ 
  - $\mathbf{p}$ 的端点是直线 $L$ 上最接近的 $\mathbf{b}$ 端点的点
  - 连接 $\mathbf{b}$ 端点和 $\mathbf{p}$ 的端点的线段垂直于直线 $L$
  - $\mathbf{p} \in C(\mathbf{a})$ 所以 $\mathbf{p} = x\mathbf{a}$
  - $\mathbf{e} = \mathbf{b} - \mathbf{p}$  垂直于 $\mathbf{a}$ 
    - $0 = \mathbf{e} \cdot \mathbf{a} = (\mathbf{b} - \mathbf{p}) \cdot \mathbf{a} = \mathbf{b} \cdot \mathbf{a} - x\mathbf{a} \cdot \mathbf{a}$
  - $x = \frac{\mathbf{b} \cdot \mathbf{a}}{\mathbf{a} \cdot \mathbf{a}}$ ,  $\mathbf{p} = \frac{\mathbf{b} \cdot \mathbf{a}}{\mathbf{a} \cdot \mathbf{a}} \mathbf{a}$



# 投影到过原点的直线上

- 考虑一条过原点的直线 $L$ , 它的方向沿着向量 $\mathbf{a}$
- 向量 $\mathbf{b}$ 在直线 $L$ 上的投影 $\mathbf{p}$

$$\cdot \mathbf{p} = \frac{\mathbf{b} \cdot \mathbf{a}}{\mathbf{a} \cdot \mathbf{a}} \mathbf{a}$$

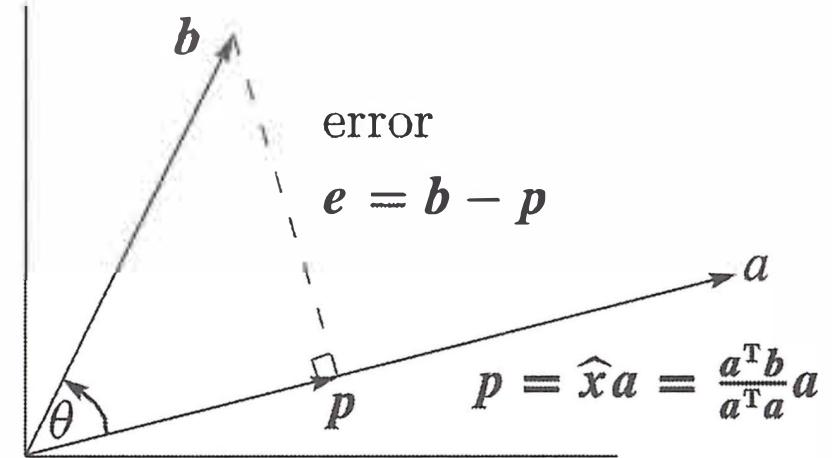
- 特殊情况 :

- $\mathbf{b}$ 和 $\mathbf{a}$ 同方向, 则 $P = I$ ,  $\mathbf{p} = \mathbf{b}$
- $\mathbf{b}$ 和 $\mathbf{a}$ 垂直, 则 $P = 0$ ,  $\mathbf{p} = \mathbf{0}$

- 例 :

$$\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \text{ onto } \mathbf{a} = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$$

$$\mathbf{p} = \frac{5}{9}\mathbf{a} = \left(\frac{5}{9}, \frac{10}{9}, \frac{10}{9}\right) \quad \mathbf{e} = \mathbf{b} - \mathbf{p} = \left(\frac{4}{9}, -\frac{1}{9}, -\frac{1}{9}\right)$$



# 投影到过原点的直线上：投影矩阵

- 考虑一条过原点的直线 $L$ , 它的方向沿着向量 $a$

- 向量 $b$ 在直线 $L$ 上的投影 $p = \frac{b \cdot a}{a \cdot a} a$

$$p = a \frac{b \cdot a}{a \cdot a} = a \frac{a^T b}{a^T a} = \frac{a a^T}{a^T a} b$$

- $p = Pb \Rightarrow P = \frac{aa^T}{a^T a}$

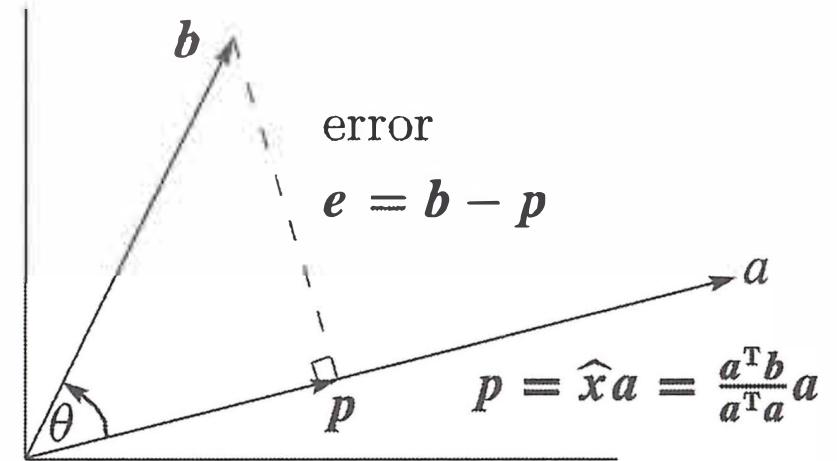
- $P$  : 列向量x行向量=矩阵。完全由 $a$ 决定

- $P^2 = P$

- 例 :

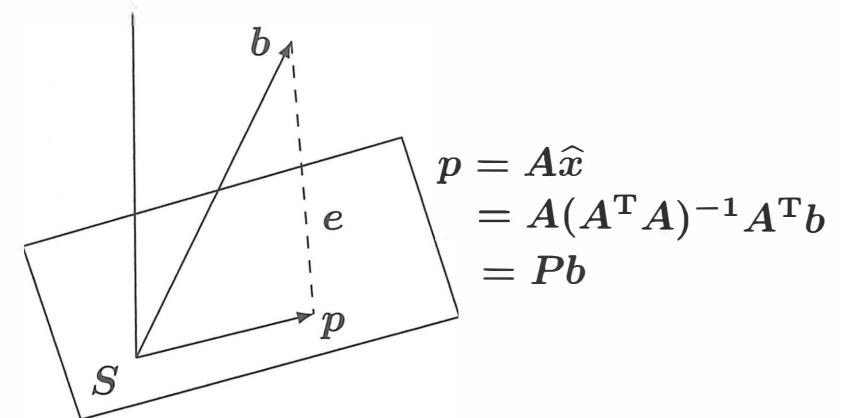
$$a = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$$

$$P = \frac{aa^T}{a^T a} = \frac{1}{9} \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix} \begin{bmatrix} 1 & 2 & 2 \end{bmatrix} = \frac{1}{9} \begin{bmatrix} 1 & 2 & 2 \\ 2 & 4 & 4 \\ 2 & 4 & 4 \end{bmatrix}$$



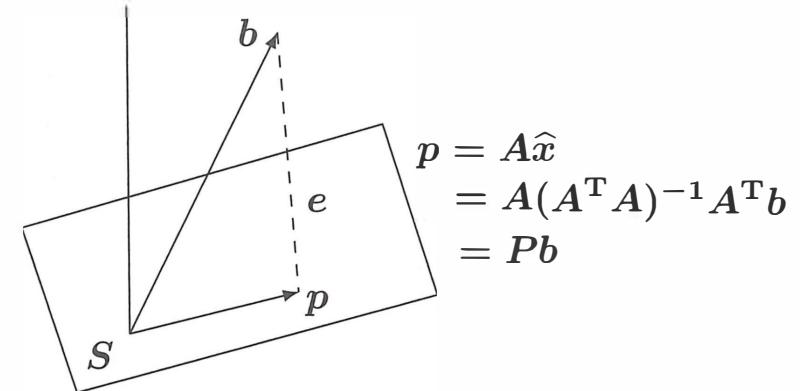
# 投影到 $\mathbb{R}^m$ 的子空间

- 考虑中 $\mathbb{R}^m$ 线性无关的n个向量 $(\mathbf{a}_1, \dots, \mathbf{a}_n)$ 张成的子空间，找到向量 $\mathbf{b}$ 在上面的投影 $\mathbf{p} = x_1 \mathbf{a}_1 + \dots + x_n \mathbf{a}_n$ 
  - $\mathbf{p}$ 的端点在子空间中距离 $\mathbf{b}$ 的端点最近
  - $\mathbf{b} - \mathbf{p}$ 同 $(\mathbf{a}_1, \dots, \mathbf{a}_n)$ 张成的子空间垂直： $(\mathbf{b} - \mathbf{p}) \cdot \mathbf{a}_i = 0$ ，对于i从1到n
- 矩阵A的列为向量 $(\mathbf{a}_1, \dots, \mathbf{a}_n)$ ，那么 $\mathbf{p} = Ax \in C(A)$ 
  - $0 = (\mathbf{b} - \mathbf{p}) \cdot \mathbf{a}_i = \mathbf{a}_i^T(\mathbf{b} - \mathbf{p})$ ，对于i从1到n
  - 等价于 $A^T(\mathbf{b} - Ax) = 0$
- 相当于求解线性方程组 $A^T A x = A^T b$



# 投影到 $\mathbb{R}^m$ 的子空间

- 考虑中  $\mathbb{R}^m$  线性无关的  $n$  个向量  $(\mathbf{a}_1, \dots, \mathbf{a}_n)$  张成的子空间，找到向量  $\mathbf{b}$  在上面的投影  $\mathbf{p} = x_1 \mathbf{a}_1 + \dots + x_n \mathbf{a}_n$
- 相当于求解线性方程组  $A^T A \mathbf{x} = A^T \mathbf{b}$ 
  - $A^T A$  :  $n \times n$  的对称矩阵
  - 如果  $A^T A$  可逆， $\mathbf{x} = (A^T A)^{-1} A^T \mathbf{b}$
  - $\mathbf{p} = A \mathbf{x} = A(A^T A)^{-1} A^T \mathbf{b}$
- 投影矩阵  $P = A(A^T A)^{-1} A^T$ 
  - 问题：用上面的公式直线  $\mathbf{a}$  的投影矩阵并和之前的结果比较
  - 证明： $P^2 = P$ ？
- 注意：不要把  $(A^T A)^{-1}$  拆成  $A^{-1}(A^T)^{-1}$ ，因为  $A$  可能不是方阵（没有逆）



# 投影到 $\mathbb{R}^m$ 的子空间

- 例 :  $A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}$  and  $b = \begin{bmatrix} 6 \\ 0 \\ 0 \end{bmatrix}$

$$A^T A = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}$$

$$A^T b = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 6 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 6 \\ 0 \end{bmatrix}$$

$$(A^T A)^{-1} = \frac{1}{6} \begin{bmatrix} 5 & -3 \\ -3 & 3 \end{bmatrix} \quad \text{and} \quad P = \frac{1}{6} \begin{bmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{bmatrix}$$

# $A^T A$ 什么时候可逆？

- 定理： $A^T A$ 可逆当且仅当 $A$ 的列之间线性无关
  - $A$ 的列之间线性无关： $A$ 满列秩、 $\text{rank}(A)=n$ 、 $\dim N(A) = 0$
- 证明：
  1.  $A^T A$ 和 $A$ 有相同的零空间
    - $Ax = 0$ 推出 $A^T Ax = 0$ , 所以 $N(A) \subset N(A^T A)$
    - $A^T Ax = 0$ 推出 $x^T A^T Ax = 0$ , 换句话说 $\|Ax\|^2 = 0$ , 长度为零的向量只能是零向量。所以 $Ax = 0$ ,  $N(A^T A) \subset N(A)$
    - $N(A) = N(A^T A)$
  2.  $A^T A$ 是 $n \times n$ 的矩阵,  $\dim N(A^T A) = 0$ 等价于 $A^T A$ 可逆
- 问题： $A^T A$ 可逆时, 用上一节的知识计算相应的子空间的维度

# $A^T A$ 可逆

• 例：

$$\begin{array}{ccc} A^T & A & A^T A \\ \left[ \begin{matrix} 1 & 1 & 0 \\ 2 & 2 & 0 \end{matrix} \right] & \left[ \begin{matrix} 1 & 2 \\ 1 & 2 \\ 0 & 0 \end{matrix} \right] & = \left[ \begin{matrix} 2 & 4 \\ 4 & 8 \end{matrix} \right] \\ \text{dependent} & \text{singular} & \end{array}$$

$$\begin{array}{ccc} A^T & A & A^T A \\ \left[ \begin{matrix} 1 & 1 & 0 \\ 2 & 2 & 1 \end{matrix} \right] & \left[ \begin{matrix} 1 & 2 \\ 1 & 2 \\ 0 & 1 \end{matrix} \right] & = \left[ \begin{matrix} 2 & 4 \\ 4 & 9 \end{matrix} \right] \\ \text{indep.} & \text{} & \text{invertible} \end{array}$$

## 小结：

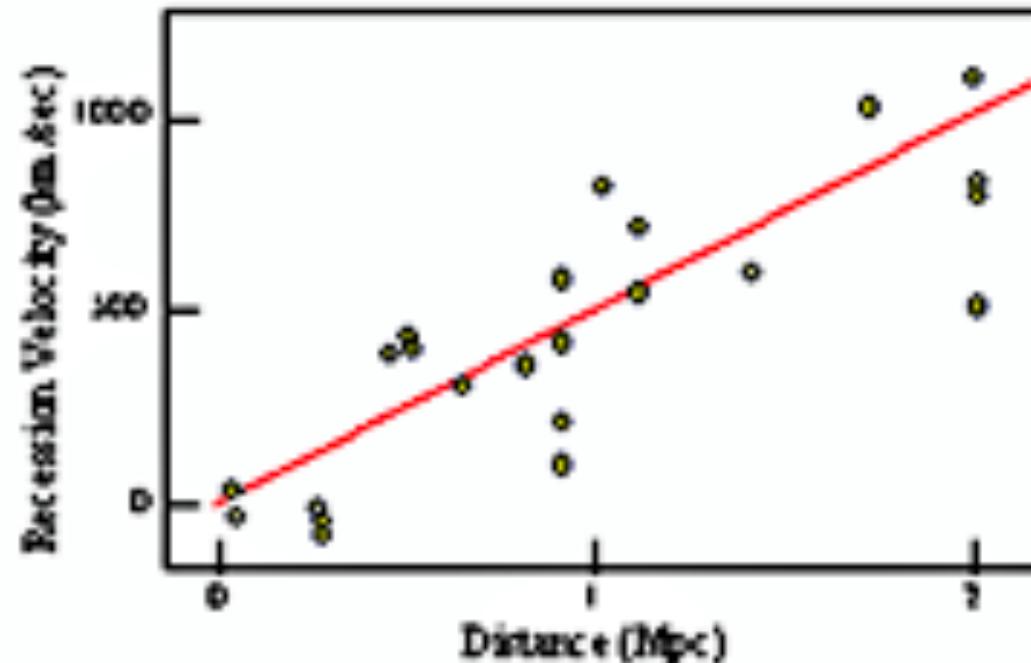
1. The projection of  $\mathbf{b}$  onto the line through  $\mathbf{a}$  is  $\mathbf{p} = \mathbf{a}\hat{x} = \mathbf{a}(\mathbf{a}^T\mathbf{b}/\mathbf{a}^T\mathbf{a})$ .
2. The rank one projection matrix  $P = \mathbf{a}\mathbf{a}^T/\mathbf{a}^T\mathbf{a}$  multiplies  $\mathbf{b}$  to produce  $\mathbf{p}$ .
3. Projecting  $\mathbf{b}$  onto a subspace leaves  $\mathbf{e} = \mathbf{b} - \mathbf{p}$  perpendicular to the subspace.
4. When  $A$  has full rank  $n$ , the equation  $A^T A \hat{x} = A^T \mathbf{b}$  leads to  $\hat{x}$  and  $\mathbf{p} = A \hat{x}$ .
5. The projection matrix  $P = A(A^T A)^{-1} A^T$  has  $P^T = P$  and  $P^2 = P$  and  $P\mathbf{b} = \mathbf{p}$ .

# 内容提要

- 正交性
- 投影
- 最小二乘法
- 正交基和Gram-Schmidt法则

# 哈勃定律

Hubble's Data (1929)

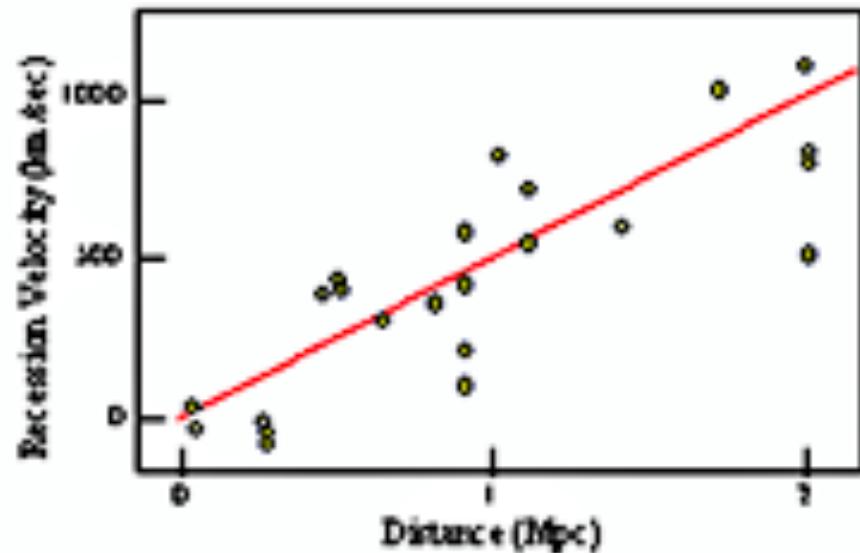


- 哈勃定律：恒星推行速度（红移量）正比于离我们的距离

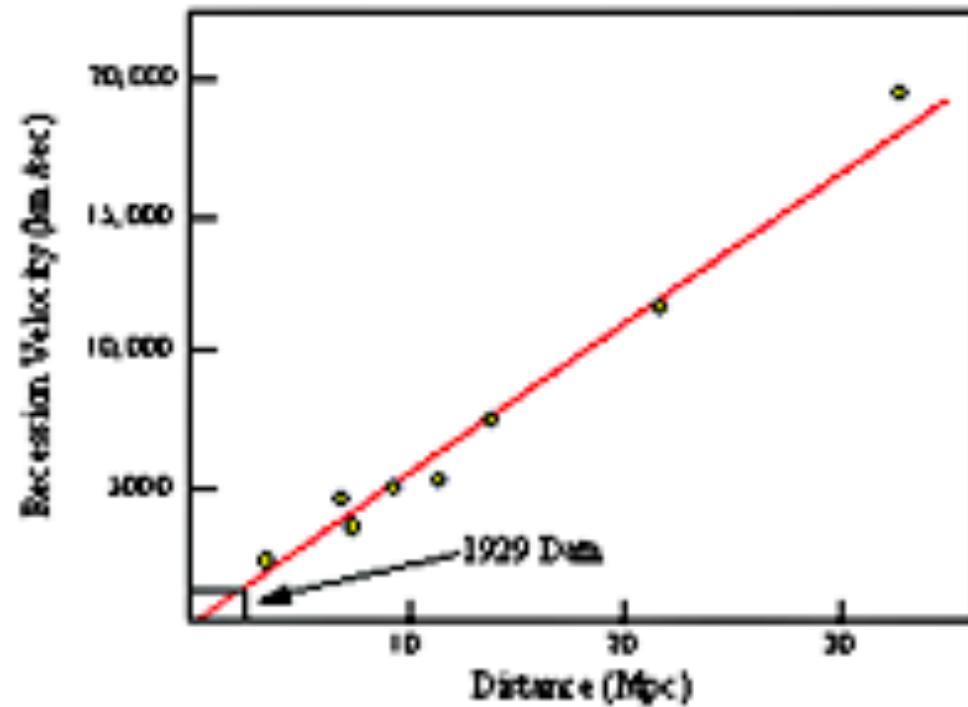
图片来源于：<https://starchild.gsfc.nasa.gov/docs/StarChild/questions/redshift.html>

# 哈勃定律

Hubble's Data (1929)



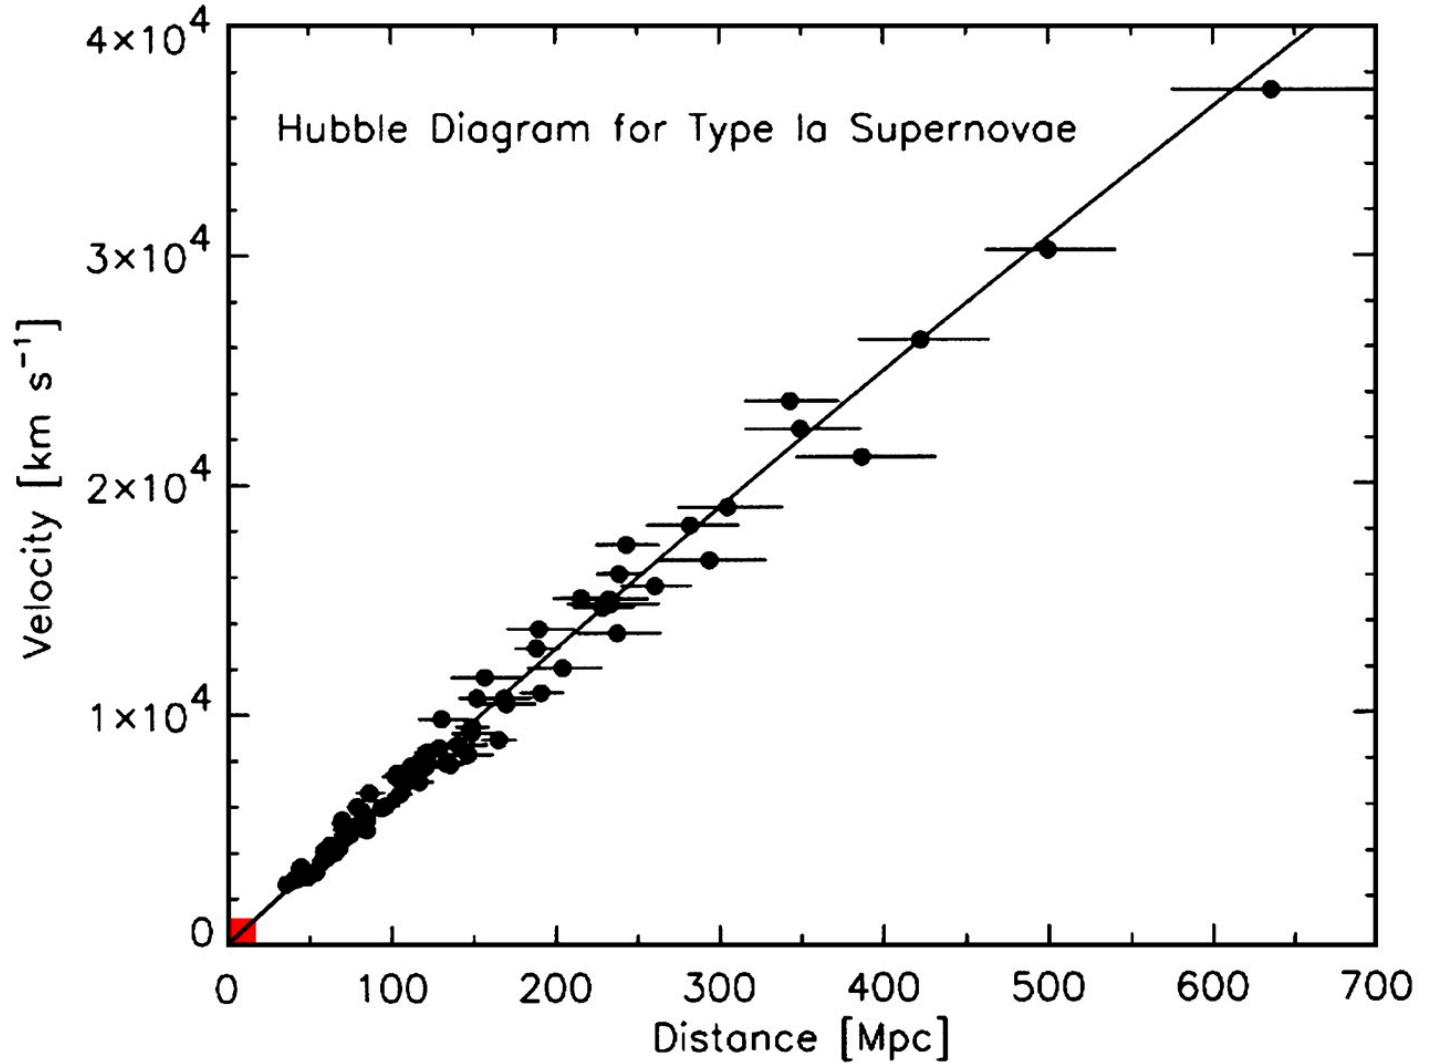
Hubble & Humason (1931)



- 哈勃定律：恒星推行速度（红移量）正比于离我们的距离

图片来源于：<https://starchild.gsfc.nasa.gov/docs/StarChild/questions/redshift.html>

# 哈勃定律



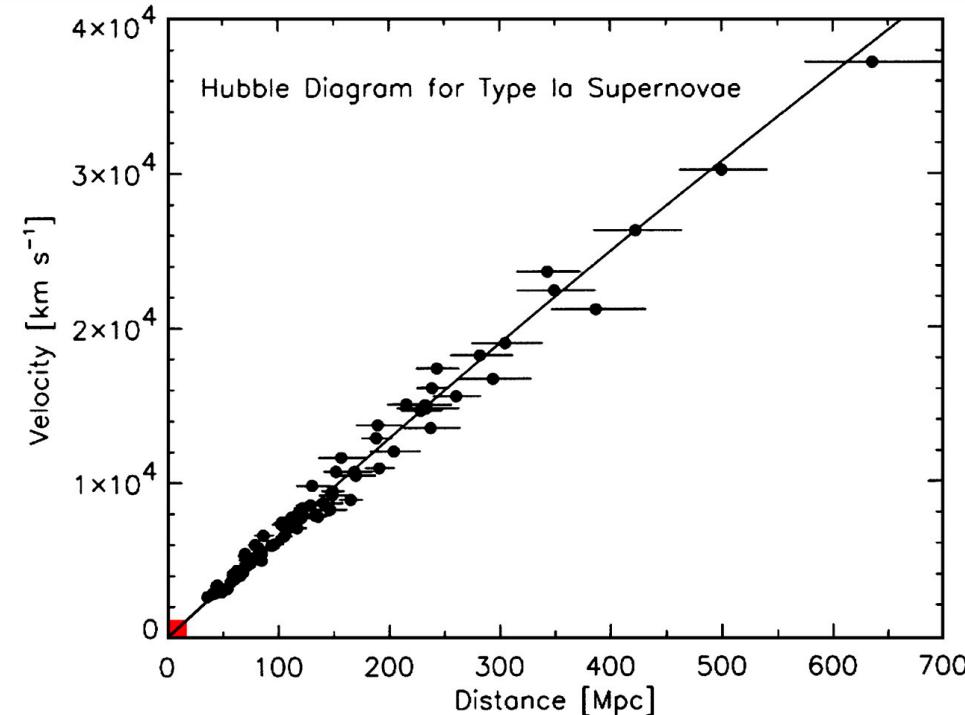
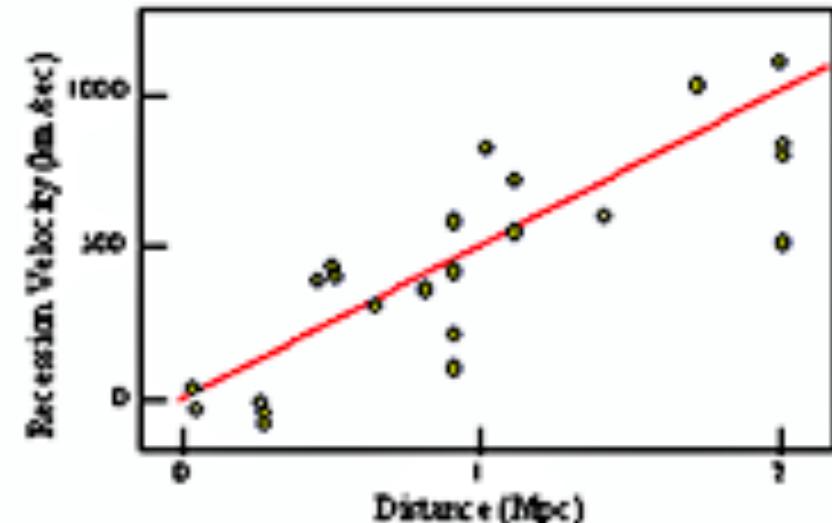
- 哈勃定律：恒星推行速度（红移量）正比于离我们的距离

图片来源于：<https://www.pnas.org/content/101/1/8/F3>

## Hubble's Data (1929)

# 拟合

- 问题1：
  - 有一组数据 $(a_i, b_i)$ , 希望找到 $b$ 和 $a$ 的关系
  - 最简单的尝试, 线性关系 $b = xa + c$
  - 如何选择参数 $x, c$ 使得总误差最小?
- 问题2：
  - 假如已知 $b = xa + c$
  - 实验测得数据 $(a, b_i)$
  - 如果确定 $x, c$ , 使得误差最小?



# 拟合

- $m$ 组数据 $(a_i, b_i)$ ,  $i$ 从1到 $m$ 
  - 确定线性关系 $b = xa + c$ 中的 $x$ 和 $c$
- 找到 $m$ 个方程构成的方程组 $b_i = xa_i + c$ ,  $i$ 从1到 $m$ 
  - 未知量为 $x$ 和 $c$ , 2个
  - 通常 $m > 2$ , 所以通常这个方程组没有解
  - 退而求其次：寻找使得每个点误差平方之和最小的解
- 最小化： $\sum_{i=1}^n (b_i - xa_i - c)^2$

# 最小二乘法

- 考虑线性方程组  $Ax = b$ 
  - $A$  :  $m \times n$  矩阵,  $m > n$ , 甚至  $m \gg n$
  - 一般来说没有解, 或者说, 不存在  $x$  使得  $e = b - Ax$  为  $\mathbf{0}$
- 找到  $x$  使得  $e = b - Ax$  的模 (长度) 最短
  - 最小化 :  $e \cdot e = \sum_{i=1}^m (b_i - \sum_{j=1}^n A_{ij} x_j)^2$
- 回忆 :  $A$  定义了一个子空间  $C(A)$ , 如果  $Ax$  是  $b$  在  $C(A)$  上的投影
  - 根据投影的定义,  $e$  的长度最短
  - $Ax = b$  没有解, 但是  $A^T A x = A^T b$  有解
  - $x = (A^T A)^{-1} A^T b$

# 拟合

- $m$ 组数据  $(a_i, b_i)$ ,  $i$ 从1到 $m$ 
  - 确定线性关系  $b = xa + c$  中的  $x$  和  $c$

- 找到  $m$  个方程构成的方程组  $b_i = xa_i + c$ ,  $i$ 从1到 $m$

$$\begin{pmatrix} 1 & a_1 \\ \vdots & \vdots \\ 1 & a_m \end{pmatrix} \begin{pmatrix} c \\ x \end{pmatrix} = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix}$$

$$\bullet A = \begin{pmatrix} 1 & a_1 \\ \vdots & \vdots \\ 1 & a_m \end{pmatrix}, \mathbf{x} = \begin{pmatrix} c \\ x \end{pmatrix}, \mathbf{b} = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix}$$

- $A$  的列秩总是2, 所以  $A^T A$  可逆,  $\mathbf{x} = (A^T A)^{-1} A^T \mathbf{b}$

例：

- 找到离 $(0, 6), (1, 0), (2, 0)$ 三个点最近的直线 $b = C + Dx$

$$C + D \cdot 0 = 6$$

$$C + D \cdot 1 = 0$$

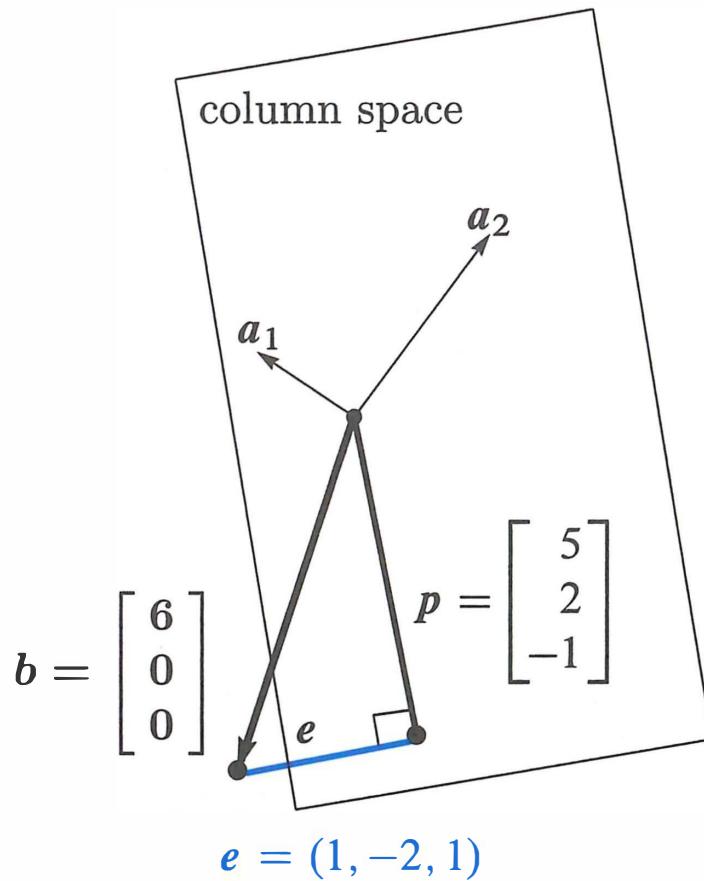
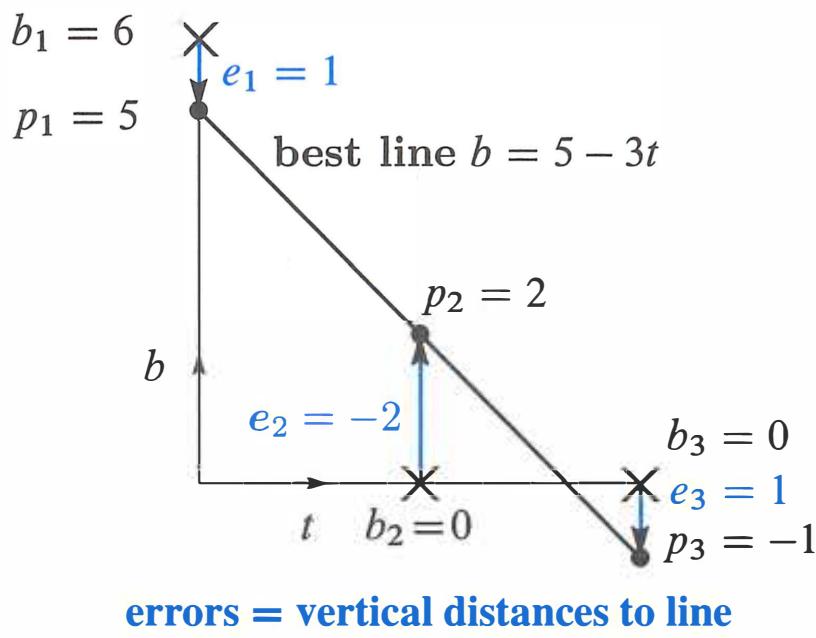
$$C + D \cdot 2 = 0.$$

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} \quad x = \begin{bmatrix} C \\ D \end{bmatrix} \quad b = \begin{bmatrix} 6 \\ 0 \\ 0 \end{bmatrix}$$

- $\begin{pmatrix} C \\ D \end{pmatrix} = \begin{pmatrix} 5 \\ -3 \end{pmatrix}, b = 5 - 3x$

例：

- 找到离 $(0, 6), (1, 0), (2, 0)$ 三个点最近的直线 $b = C + Dx$
- $\begin{pmatrix} C \\ D \end{pmatrix} = \begin{pmatrix} 5 \\ -3 \end{pmatrix}, b = 5 - 3x$



证明： $\mathbf{x} = (A^T A)^{-1} A^T \mathbf{b}$ 使 $\|A\mathbf{x} - \mathbf{b}\|^2$ 最小

- 几何：投影端点是子空间中距离原向量 $\mathbf{b}$ 端点最近的点
- 代数：
  - 考虑 $C(A)$ 和它在 $\mathbb{R}^m$ 中的正交补 $C(A)^\perp$ ,  $A\mathbf{x} \in C(A)$
  - 将 $\mathbf{b}$ 分解为 $\mathbf{b} = \mathbf{p} + \mathbf{e}$ ,  $\mathbf{p} \in C(A)$ ,  $\mathbf{e} \in C(A)^\perp$ ,  $\mathbf{p}$ 是 $\mathbf{b}$ 在 $C(A)$ 中的投影
  - $\|A\mathbf{x} - \mathbf{b}\|^2 = \|A\mathbf{x} - \mathbf{p}\|^2 + \|\mathbf{e}\|^2$
  - 最小化 $\|A\mathbf{x} - \mathbf{b}\|^2$ 要求 $A\mathbf{x} - \mathbf{p} = \mathbf{0}$ , 解出 $\mathbf{x}$
- 微积分：
  - $\frac{\partial}{\partial x_i} \|A\mathbf{x} - \mathbf{b}\|^2 = 0 \Rightarrow A^T A \mathbf{x} = A^T \mathbf{b}$

# Big Picture (升级版2)

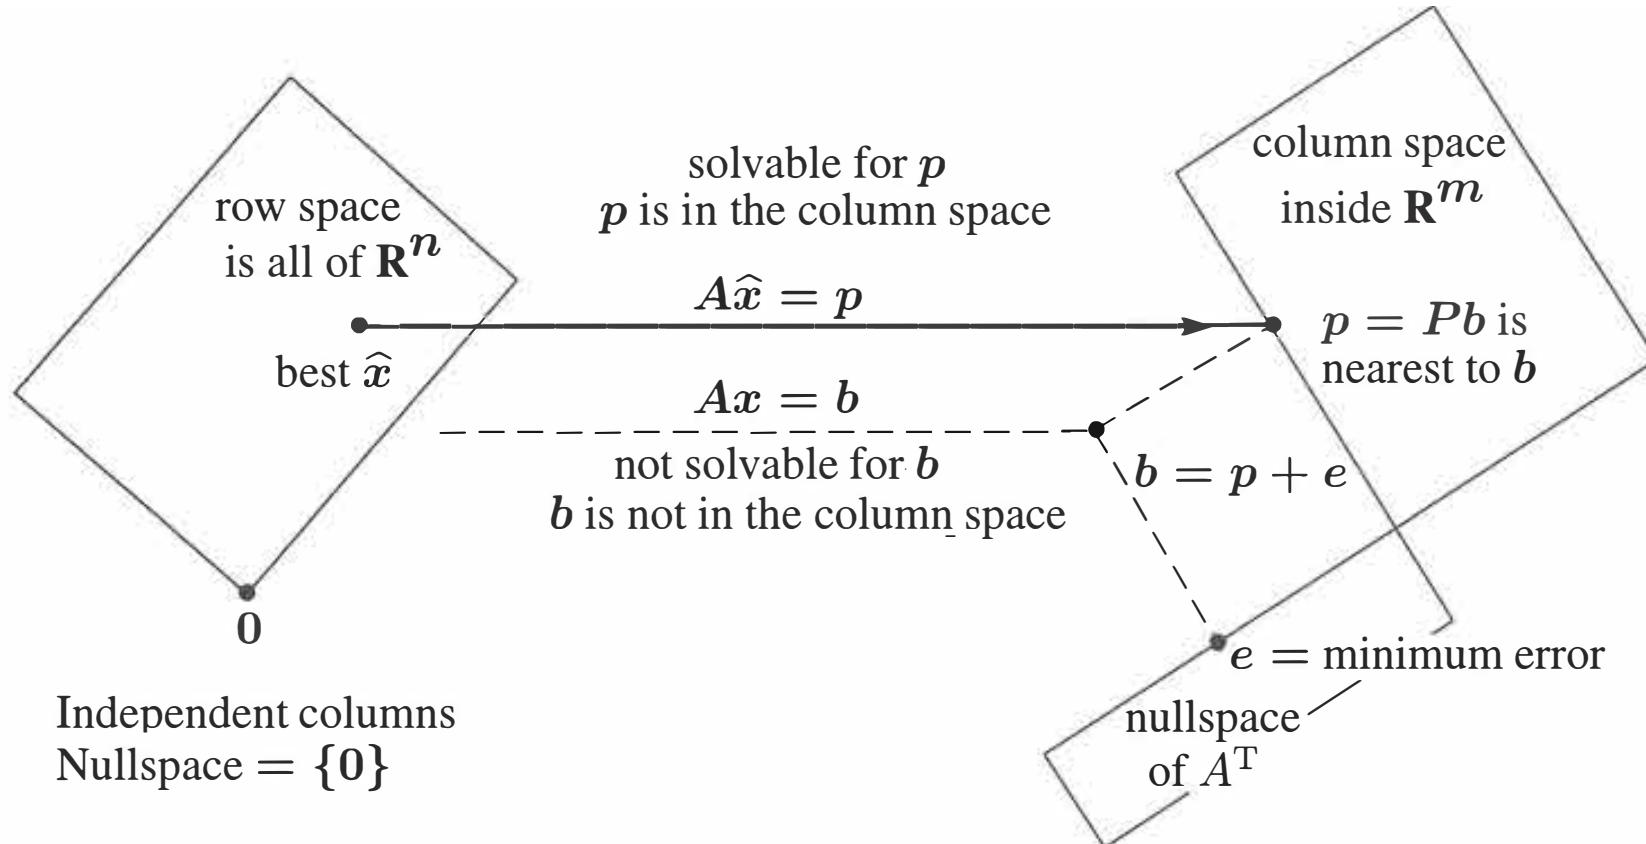


Figure 4.7: The projection  $p = A\hat{x}$  is closest to  $b$ , so  $\hat{x}$  minimizes  $E = \|b - Ax\|^2$ .

# 多项式拟合

- m组数据 $(a_i, b_i)$ , i从1到m

- 确定多项式关系 $b = c_0 + c_1a + c_2a^2 \cdots + c_na^n$ 中的 $c_i$ , i从0到n

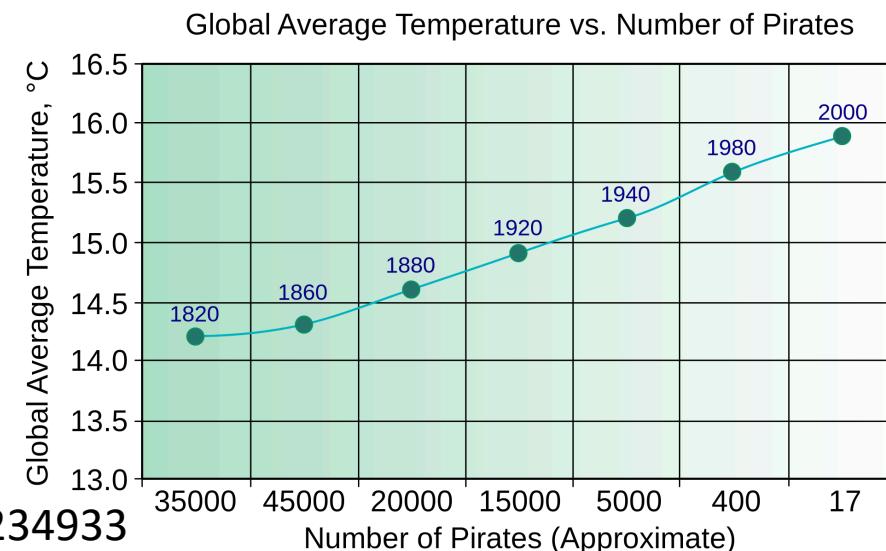
$$A = \begin{pmatrix} 1 & a_1 & a_1^2 & \cdots & a_1^n \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 1 & a_m & a_m^2 & \cdots & a_m^n \end{pmatrix}, \boldsymbol{x} = \begin{pmatrix} c_0 \\ c_1 \\ \vdots \\ c_n \end{pmatrix}, \boldsymbol{b} = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix}$$

- 拟合 :  $A\boldsymbol{x} = \boldsymbol{b}$

- $\boldsymbol{x} = (A^T A)^{-1} A^T \boldsymbol{b}$

# 一般最小二乘拟合

- 问题：一组数据 $\{a_i, b_i\}$ , 关系 $b = f(a; \{c_j\})$ , 找到参数 $\{c_i\}$ 使得 $\sum_i (b_i - f(a_i; \{c_j\}))^2$ 最小
  - 多项式拟合：对于参数 $\{c_j\}$ 是线性的，可以用前面讲的线性拟合
  - $c_0 a^{c_1}, c_0 e^{c_1 a}$ 等等：先转化成线性关系，再拟合
  - 更一般的函数 $f(a; \{c_j\})$ ：先对 $\sum_i (b_i - f(a_i; \{c_j\}))^2$ 求偏导数，再找偏导数为0的点（一般通过数值方法、迭代）
- 更复杂：不知道 $f(a; \{c_j\})$ 的具体形式
  - 神经网络、机器学习、……
- 两组数据相关不一定代表有因果



图片来源于：<https://commons.wikimedia.org/w/index.php?curid=15234933>

# 小结

1. The least squares solution  $\hat{\mathbf{x}}$  minimizes  $\|A\mathbf{x} - \mathbf{b}\|^2 = \mathbf{x}^T A^T A \mathbf{x} - 2\mathbf{x}^T A^T \mathbf{b} + \mathbf{b}^T \mathbf{b}$ .  
This is  $E$ , the sum of squares of the errors in the  $m$  equations ( $m > n$ ).
2. The best  $\hat{\mathbf{x}}$  comes from the normal equations  $A^T A \hat{\mathbf{x}} = A^T \mathbf{b}$ .  $E$  is a minimum.
3. To fit  $m$  points by a line  $b = C + Dt$ , the normal equations give  $C$  and  $D$ .
4. The heights of the best line are  $\mathbf{p} = (p_1, \dots, p_m)$ . The vertical distances to the data points are the errors  $\mathbf{e} = (e_1, \dots, e_m)$ . A key equation is  $A^T \mathbf{e} = \mathbf{0}$ .
5. If we try to fit  $m$  points by a combination of  $n < m$  functions, the  $m$  equations  $A\mathbf{x} = \mathbf{b}$  are generally unsolvable. The  $n$  equations  $A^T A \hat{\mathbf{x}} = A^T \mathbf{b}$  give the least squares solution—the combination with smallest MSE (mean square error).

# 内容提要

- 正交性
- 投影
- 最小二乘法
- 正交基和Gram-Schmidt法则

# 正交基

- 基：一组线性无关的向量并且张成整个线性空间