

# 奇异值分解

颜文斌  
清华大学

# 内容提要

- 奇异值分解
- 主成分分析
- 奇异值分解和几何

# 矩阵对角化

- 矩阵对角化有很多应用：简化计算、解方程.....
- 不是所有矩阵都可以对角化的
  - 可对角化矩阵例：对称矩阵
- 特征值和特征向量只使用于方阵
- 对于一般的 $m \times n$ 矩阵 $A$ ，有没有类似的操作？
  - 回忆方程 $Ax = b$ 不一定有解，但是 $A^T Ax = A^T b$ 有解
  - 考虑方阵 $A^T A$ 和 $AA^T$ ，他们都是**半正定**矩阵，所以可以对角化而且特征值大于等于0

# 对角化 $A^T A$ 和 $AA^T$

- $m \times n$  矩阵  $A$ ,  $A^T A$  和  $AA^T$  都是**半正定**矩阵,
  - 证明:  $\forall \mathbf{x}, \mathbf{x}^T A^T A \mathbf{x} = \|A \mathbf{x}\|^2 \geq 0$ , 所以  $A^T A$  是半正定的。  $AA^T$  同理
- $A^T A$  和  $AA^T$  都可以对角化
  - $A^T A = V \Lambda_1 V^T$ ,  $AA^T = U \Lambda_2 U^T$
  - $V^T A^T A V = (AV)^T A(V) = \Lambda_1$
  - $U^T A A^T U = (U^T) A (A^T U) = \Lambda_2$
- 猜测: 找到正交矩阵  $U$  和  $V$  使得  $m \times n$  矩阵  $U^T A V$  可以写成  $\Sigma$ ? 其中  $\Sigma$  是某种意义上的“对角”矩阵

# 奇异值 (singular value)

- $m \times n$  的实矩阵  $A$ ,  $A^T A$  是一个  $n \times n$  的对称矩阵,  $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n\}$  是由  $A^T A$  的特征向量构成的  $\mathbb{R}^n$  中的正交归一基, 对应的实特征值为  $\{\lambda_1, \lambda_2, \dots, \lambda_n\}$ , 假设  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$
- $A^T A$  的所有特征值都非负:  $\|A\mathbf{q}_i\|^2 = \mathbf{q}_i^T A^T A \mathbf{q}_i = \lambda_i \geq 0$
- 矩阵  $A$  的奇异值定义为  $A^T A$  的特征值的平方根:  $\sigma_i = \sqrt{\lambda_i}$ 
  - $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0$
  - $\sigma_i = \|A\mathbf{q}_i\|$

# 例

- 求以下矩阵的奇异值

$$A = \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix} \quad A^T A = \begin{bmatrix} 4 & 8 \\ 11 & 7 \\ 14 & -2 \end{bmatrix} \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix} = \begin{bmatrix} 80 & 100 & 40 \\ 100 & 170 & 140 \\ 40 & 140 & 200 \end{bmatrix}$$

- 特征方程：
$$\det \begin{bmatrix} 80 - \lambda & 100 & 40 \\ 100 & 170 - \lambda & 140 \\ 40 & 140 & 200 - \lambda \end{bmatrix}$$
$$= -\lambda(\lambda - 90)(\lambda - 360)$$

- 特征值：360, 90, 0。奇异值： $6\sqrt{10}$ ,  $3\sqrt{10}$ , 0

# $A$ 的秩和 $A^T A$ 的秩

- 定理：  $m \times n$  矩阵  $A$ ,  $\text{rank}(A^T A) = \text{rank}(A)$
- 证明：
  - $\text{rank}(A^T A) = n - \dim N(A^T A)$ ,  $\text{rank}(A) = n - \dim N(A)$ , 所以我们只需证明  $\dim N(A^T A) = \dim N(A)$
  - 如果  $\mathbf{x} \in N(A)$ , 则  $A\mathbf{x} = 0$ , 等号两边同时左乘  $A^T$  得到  $A^T A\mathbf{x} = 0$ , 所以  $\mathbf{x} \in N(A^T A)$
  - 如果  $\mathbf{x} \in N(A^T A)$ , 则  $A^T A\mathbf{x} = 0$ , 等号两边同时左乘  $\mathbf{x}^T$  得到  $\mathbf{x}^T A^T A\mathbf{x} = 0$ , 所以  $\|A\mathbf{x}\|^2 = 0$ , 所以  $A\mathbf{x} = 0$ , 所以  $\mathbf{x} \in N(A)$
  - $N(A)$  和  $N(A^T A)$  存在一一映射, 所以  $\dim N(A^T A) = \dim N(A)$ ,
- 推论： $\text{rank}(A) = \text{rank}(A^T) = \text{rank}(AA^T) = \text{rank}(A^T A)$

# 非零奇异值的数量

- 定理： $m \times n$ 的实矩阵 $A$ 的非零奇异值 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ 的个数 $r$ 等于 $A$ 的秩 $\text{rank}(A)$
- 证明：
  - 设 $\{\mathbf{v}_1, \cdots, \mathbf{v}_n\}$ 为 $\mathbb{R}^n$ 中可以把 $A^T A$ 对角化的正交归一基， $\{\lambda_1, \cdots, \lambda_n\}$ 为对应的特征值，则 $\{A\mathbf{v}_1, \cdots, A\mathbf{v}_n\}$ 是一个**正交向量集合**，也就是说 $\forall i \neq j$ ,  
 $(A\mathbf{v}_i)^T (A\mathbf{v}_j) = \mathbf{v}_i^T A^T A \mathbf{v}_j = \mathbf{v}_i^T (\lambda_j \mathbf{v}_j) = 0$
  - 假设 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$ 是所有正特征值， $\lambda_{r+1} = \lambda_{r+2} = \cdots = \lambda_n = 0$ 是所有0特征值，则 $\{A\mathbf{v}_{r+1}, \cdots, A\mathbf{v}_n\}$ 都是零向量
  - 因为 $\{\mathbf{v}_1, \cdots, \mathbf{v}_n\}$ 为 $\mathbb{R}^n$ 中可以把 $A^T A$ 对角化的正交归一基，所以对于任意的 $\mathbf{x} \in \mathbb{R}^n$ ， $\mathbf{x}$ 可以写成 $\mathbf{x} = c_1 \mathbf{v}_1 + \cdots + c_n \mathbf{v}_n$ 。



# 非零奇异值的数量（续）

- 定理： $m \times n$ 的实矩阵 $A$ 的非零奇异值 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ 的个数 $r$ 等于 $A$ 的秩 $\text{rank}(A)$
- 证明（续）：
  - 因为 $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ 为 $\mathbb{R}^n$ 中可以把 $A^T A$ 对角化的正交归一基，所以对于任意的 $\mathbf{x} \in \mathbb{R}^n$ ， $\mathbf{x}$ 可以写成 $\mathbf{x} = c_1 \mathbf{v}_1 + \cdots + c_n \mathbf{v}_n$ 。
  - 我们需要证明 $A$ 的秩为 $r$ ，只需要证明列空间 $C(A)$ 的维度为 $r$ ，需要找到列空间的一组基
  - 因为 $C(A)$ 是由 $A$ 所有列的线性组合得到的，所以 $\forall \mathbf{y} \in C(A)$ ， $\mathbf{y} = A\mathbf{x} = c_1 A\mathbf{v}_1 + \cdots + c_n A\mathbf{v}_n = c_1 A\mathbf{v}_1 + \cdots + c_r A\mathbf{v}_r$ ，也就是说 $C(A)$ 中的任何向量都可以写成 $\{A\mathbf{v}_1, \dots, A\mathbf{v}_r\}$ 的线性组合
  - 所以 $\{A\mathbf{v}_1, \dots, A\mathbf{v}_r\}$ 是 $C(A)$ 的一组正交基，所以 $r = \text{rank}(A)$

# 奇异值分解：陈述

- 广义“对角”矩阵： $m \times n$ 矩阵 $\Sigma$

$$\Sigma = \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix}$$

- $D$ 是一个 $r \times r$ 的对角矩阵， $\Sigma$ 所有大于 $r$ 的行和列都是0

- **定理（奇异值分解）**： $m \times n$ 矩阵 $A$ 的秩为 $r$ 。则存在一个形状如上的 $m \times n$ 矩阵 $\Sigma$ 且 $D$ 的对角元是 $A$ 的前 $r$ 个（非零）的奇异值， $m \times m$ 的正交矩阵 $U$ 和 $n \times n$ 的正交矩阵 $V$ ，而且以上矩阵满足关系

$$A = U\Sigma V^T$$

- 可以用两个正交矩阵把任意矩阵 $A$ 变成简单形式
- 考虑 $\text{rank}(A)=1$ ，矩阵可以写成两个向量的乘积（压缩）

# 奇异值分解：证明

- 证明：直接构造相应的矩阵
  - $A^T A$ 是对称矩阵，由谱定理可知存在一组 $\mathbb{R}^n$ 中的正交归一基，将 $A^T A$ 对角化
  - 设 $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ 为 $\mathbb{R}^n$ 中可以把 $A^T A$ 对角化的正交归一基， $\{\lambda_1, \dots, \lambda_n\}$ 为对应的特征值。由之前定理 $\{\lambda_1, \dots, \lambda_r\}$ 是正特征值， $\{\lambda_{r+1}, \dots, \lambda_n\}$ 是零特征值
  - 因为 $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ 之间是正交的，则 $\forall i \neq j$ ,  $(A\mathbf{v}_i)^T (A\mathbf{v}_j) = \mathbf{v}_i^T A^T A \mathbf{v}_j = \mathbf{v}_i^T (\lambda_j \mathbf{v}_j) = 0$ ，所以 $\{A\mathbf{v}_1, \dots, A\mathbf{v}_r\}$ 之间也是正交的， $\{A\mathbf{v}_{r+1}, \dots, A\mathbf{v}_n\}$ 是零向量
  - 令 $u_i = \frac{1}{\|A\mathbf{v}_i\|} A\mathbf{v}_i = \frac{1}{\sigma_i} A\mathbf{v}_i$ ,  $i = 1, \dots, r$ ，则 $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ 是 $C(A)$ 的一组正交归一基。 $\sigma_i = \sqrt{\lambda_i}$

# 奇异值分解：证明（续）

- 证明：直接构造相应的矩阵

- 令  $u_i = \frac{1}{\|Av_i\|} Av_i = \frac{1}{\sigma_i} Av_i$ ,  $i = 1, \dots, r$ , 则  $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$  是  $C(A)$  的一组正交归一基。  $\sigma_i = \sqrt{\lambda_i}$
- 再设  $\{\mathbf{u}_{r+1}, \dots, \mathbf{u}_m\}$  是  $N(A^T)$  中的一组正交归一基。因为  $N(A^T)$  是  $C(A)$  的正交补, 则  $\{\mathbf{u}_1, \dots, \mathbf{u}_m\}$  是  $\mathbb{R}^m$  的一组正交归一基
- 设矩阵  $U = (\mathbf{u}_1, \dots, \mathbf{u}_m)$  和  $V = (\mathbf{v}_1, \dots, \mathbf{v}_n)$ ,  $U$  和  $V$  都是正交的
- $AV = (Av_1, \dots, Av_n) = (\sigma_1 \mathbf{u}_1, \dots, \sigma_r \mathbf{u}_r, 0, \dots, 0) = U\Sigma$
- 所以  $A = U\Sigma V^T$ , 我们得到了  $A$  的奇异值分解  $A = U\Sigma V^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$

# 奇异值分解：例

- 矩阵  $A = \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix}$  的奇异值分解
- $A^T A = \begin{bmatrix} 80 & 100 & 40 \\ 100 & 170 & 140 \\ 40 & 140 & 200 \end{bmatrix}$
- $A^T A$  的特征值：360, 90, 0。  $A$  的奇异值： $6\sqrt{10}$ ,  $3\sqrt{10}$ , 0
- $V = \begin{bmatrix} 1/3 & -2/3 & 2/3 \\ 2/3 & -1/3 & -2/3 \\ 2/3 & 2/3 & 1/3 \end{bmatrix}$

# 奇异值分解——例

- 矩阵  $A = \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix}$  的奇异值分解
- $A$  的奇异值：  $6\sqrt{10}$ ,  $3\sqrt{10}$ ,  $0$
- $V = \begin{bmatrix} 1/3 & -2/3 & 2/3 \\ 2/3 & -1/3 & -2/3 \\ 2/3 & 2/3 & 1/3 \end{bmatrix}$ ,  $AV = \begin{bmatrix} 4 & 11 \\ 8 & 7 \end{bmatrix}$
- $\mathbf{u}_1 = \frac{1}{\sigma_1} A \mathbf{v}_1 = \begin{bmatrix} 3/\sqrt{10} \\ 1/\sqrt{10} \end{bmatrix}$ ,  $\mathbf{u}_2 = \frac{1}{\sigma_2} A \mathbf{v}_2 = \begin{bmatrix} 1/\sqrt{10} \\ -3/\sqrt{10} \end{bmatrix}$
- $U = (\mathbf{u}_1 \quad \mathbf{u}_2)$

# 奇异值分解——例

• 矩阵  $A = \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix}$  的奇异值分解  $A = U\Sigma V^T$

•  $A$  的奇异值：  $6\sqrt{10}$ ,  $3\sqrt{10}$ ,  $0$ ,  $\Sigma = \begin{bmatrix} 6\sqrt{10} & 0 & 0 \\ 0 & 3\sqrt{10} & 0 \end{bmatrix}$

•  $V = \begin{bmatrix} 1/3 & -2/3 & 2/3 \\ 2/3 & -1/3 & -2/3 \\ 2/3 & 2/3 & 1/3 \end{bmatrix}$ ,  $U = \begin{bmatrix} 3/\sqrt{10} & 1/\sqrt{10} \\ 1/\sqrt{10} & -3/\sqrt{10} \end{bmatrix}$

•  $A = \begin{bmatrix} 3/\sqrt{10} & 1/\sqrt{10} \\ 1/\sqrt{10} & -3/\sqrt{10} \end{bmatrix} \begin{bmatrix} 6\sqrt{10} & 0 & 0 \\ 0 & 3\sqrt{10} & 0 \end{bmatrix} \begin{bmatrix} 1/3 & 2/3 & 2/3 \\ -2/3 & -1/3 & 2/3 \\ 2/3 & -2/3 & 1/3 \end{bmatrix}$

# $A$ 和 $A^T$ 的奇异值分解

- 练习：矩阵 $A^T = \begin{bmatrix} 4 & 8 \\ 11 & 7 \\ 14 & -2 \end{bmatrix}$ 的奇异值分解
- 思考：已知 $A$ 的奇异值分解，求矩阵 $A^T$ 的奇异值分解？
- 结论：若 $A$ 的奇异值分解为 $U\Sigma V^T$ ， $A^T$ 的奇异值分解为 $A^T = V\Sigma U^T$
- 推论： $\{\mathbf{u}_1, \dots, \mathbf{u}_m\}$ 是矩阵 $AA^T$ 的特征向量
- 证明：
  - $AA^T = U\Sigma V^T V\Sigma U^T = U\Sigma^2 U^T$ ，所以 $AA^T U = U\Sigma^2$
- $V$ 和 $U$ 分别是将 $A^T A$ 和 $AA^T$ 对角化的正交矩阵



# $A$ 和 $A^T$ 的奇异值分解

- **定理：**  $A^T A$ 和 $AA^T$ 的非零特征值都相同
- **证明：**可以直接用 $A$ 的奇异值分解证明，我们这里直接证明
  - 假设 $x_i$ 是 $A^T A$ 的特征值为 $\lambda_i \neq 0$ 的特征向量， $(\lambda_i I - A^T A)x_i = 0$
  - 等号两端同时左乘： $0 = A(\lambda_i I - A^T A)x_i = (\lambda_i A - AA^T A)x_i = (\lambda_i I - AA^T)(Ax_i)$ 。又因为 $x^T A^T A x = \lambda_i x^T x > 0$ ，所以 $Ax_i \neq 0$ 。所以 $Ax_i$ 是 $AA^T$ 的特征值为 $\lambda_i$ 的特征向量
  - 同理，如果 $x_i$ 是 $AA^T$ 的特征值为 $\lambda_i \neq 0$ 的特征向量， $A^T x_i$ 是 $A^T A$ 的特征值为 $\lambda_i$ 的特征向量
  - 这样，我们就有 $A^T A$ 和 $AA^T$ 非零特征值和非零特征向量的一一对应

# 应用：四个子空间的正交归一基

- $A = U\Sigma V^T$ 
  - $\{\boldsymbol{v}_1, \dots, \boldsymbol{v}_r\}$  是  $C(A^T)$  的正交归一基,  $V_r = (\boldsymbol{v}_1, \dots, \boldsymbol{v}_r)$
  - $\{\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n\}$  是  $N(A)$  的正交归一基,  $V_{n-r} = (\boldsymbol{v}_{r+1}, \dots, \boldsymbol{v}_n)$
  - $\{\boldsymbol{u}_1, \dots, \boldsymbol{u}_r\}$  是  $C(A)$  的正交归一基,  $U_r = (\boldsymbol{u}_1, \dots, \boldsymbol{u}_r)$
  - $\{\boldsymbol{u}_{r+1}, \dots, \boldsymbol{u}_m\}$  是  $N(A^T)$  的正交归一基,  $U_{n-r} = (\boldsymbol{u}_{r+1}, \dots, \boldsymbol{u}_m)$
- 证明？

# 应用：数据压缩

- 假设 $\text{rank}(A) < \min(m, n)$ , 则

$$A = (U_r, U_{m-r}) \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} V_r^T \\ V_{n-r}^T \end{bmatrix} = U_r D V_r^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

- 可以用 $U_r, D, V_r$ 这三个矩阵的 $r(m+1+n)$ 个分量完全决定 $A$  ( $mn$ )
- **图像压缩**
  - 先考虑黑白图片, 可以用一个 $m \times n$ 的矩阵描述, 每个元素是该像素的灰度 (0-255之间的整数, 0是黑, 255是白)
  - 如果 $r(m+1+n) < mn$ , 我们可以只储存或者传输 $U_r, D, V_r$  (无损)。例如矩阵秩为1的时候我们只需要储存一个行向量和一个列向量
  - 甚至可以把很小的奇异值当成零忽略, 进一步压缩图片 (有损)

# 数据压缩的误差估计

- $A = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ , 我们需要估算取前k个奇异值得到的矩阵和真实矩阵之间的误差

- 设  $A(k) = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$ , 则  $\delta A = A - A(k) = \sum_{l=k+1}^r \sigma_l \mathbf{u}_l \mathbf{v}_l^T$

- $\delta A$ 的ij分量的绝对值:

$$|\delta A_{ij}| = \left| \sum_{l=k+1}^r \sigma_l (\mathbf{u}_l)_i (\mathbf{v}_l^T)_j \right| \leq \sum_{l=k+1}^r \sigma_l |(\mathbf{u}_l)_i| |(\mathbf{v}_l^T)_j|$$

- $\mathbf{u}_l$ ,  $\mathbf{v}_l$ 的长度都是1, 所以  $|(\mathbf{u}_l)_i| \leq 1$ ,  $|(\mathbf{v}_l^T)_j| \leq 1$

- 所以  $|\delta A_{ij}| \leq \sum_{l=k+1}^r \sigma_l$

- 结论: 误差由忽略的奇异值控制, 取得奇异值越多误差越小

# 图像压缩例

- 一个 $128 \times 623 = 79744$ 像素的黑白图片
  - 秩为24。奇异值分解后有效信息 $24 \times (128 + 623) = 18024$
  - 取前 $k$ 个奇异值的近似

504192



k=1



k=3



k=5



k=10

# 图像压缩例

- 考虑一个300x300的下三角矩阵， 对角线和下面的元素全是255



原图：300x300



前1个奇异值 ~ 600



前5个 ~ 3000




前10个 ~ 6000



前30个 ~ 18000



前60个 ~ 36000



前100个 ~ 60000

# 小结

1. The SVD factors  $A$  into  $U\Sigma V^T$ , with  $r$  singular values  $\sigma_1 \geq \dots \geq \sigma_r > 0$ .
2. The numbers  $\sigma_1^2, \dots, \sigma_r^2$  are the nonzero eigenvalues of  $AA^T$  and  $A^T A$ .
3. The orthonormal columns of  $U$  and  $V$  are eigenvectors of  $AA^T$  and  $A^T A$ .
4. Those columns hold orthonormal bases for the four fundamental subspaces of  $A$ .
5. Those bases diagonalize the matrix:  $A\mathbf{v}_i = \sigma_i \mathbf{u}_i$  for  $i \leq r$ . This is  $\mathbf{A}\mathbf{V} = \mathbf{U}\Sigma$ .
6.  $A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \dots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T$  and  $\sigma_1$  is the maximum of the ratio  $\|A\mathbf{x}\| / \|\mathbf{x}\|$ .

# 内容提要

- 奇异值分解
- 主成分分析
- 奇异值分解和几何



# 统计知识

- 假设一组数据来源于n个样本 $\{\mu_1, \mu_2, \dots, \mu_n\}$
- 例：所有同学的期中考试成绩
- 平均值 (mean) :  $\bar{\mu} = \frac{\sum_i \mu_i}{n}$
- 标准差 (standard deviation) :  $\sigma = \sqrt{\frac{\sum_{i=1}^n (\mu_i - \bar{\mu})^2}{n-1}}$ 
  - n-1个自由度，因为平均值也是一个自由度
  - 数据的分散程度，标准差越大，数据越分散：

# 统计知识

- 假设n个样本，每个样本i我们得到两个数据 $\mu_i$ 和 $\rho_i$
- 例：所有同学的期中考试成绩和平时作业成绩
- **协方差**：
$$\text{cov}(\mu, \rho) = \frac{\sum_{i=1}^n (\mu_i - \bar{\mu})(\rho_i - \bar{\rho})}{n-1}$$
  - 描述了 $\mu$ 和 $\rho$ 之间的相关性
  - $\text{cov}(\mu, \rho) > 0$ 正相关， $\text{cov}(\mu, \rho) < 0$ 负相关

# 协方差矩阵

- 将数据存在一个 $m \times n$ 的矩阵 $A_0$ 中，每一行对应一种数据，每一列代表一个样本
- 矩阵 $A$ 由 $A_0$ 的每一个元素减去它所在行的平均值得到

$$A_{ij} = (A_0)_{ij} - \frac{\sum_{k=1}^n (A_0)_{ik}}{n}$$

- $A$ 中每一行的数据都是以0为中心分布
- **协方差矩阵 (covariance matrix)** :
$$S = \frac{AA^T}{n-1}$$
  - $S_{ii}$  : 第 $i$ 种数据的**标准差**。  $S_{ij}$  : 第 $i$ 种和第 $j$ 种数据的**协方差**

例：

应用：最小二乘法